Question: Tôi có ESP32-S3 N16R8 + Sipeed Tang Nano 20K. Nên dùng model nào chạy trực tiếp trên 2 board đó để cho kết quả nhận diện tốt nhất?

Answer: Với việc sở hữu **ESP32-S3 (N16R8)** và FPGA **Sipeed Tang Nano 20K**, bạn đang có trong tay hai cấu hình phần cứng có hiệu năng xử lý phần cứng và AI mạnh hơn rất nhiều so với chip ESP32 đời cũ. Tuy nhiên, hai bo mạch này sử dụng hai kiến trúc hoàn toàn khác nhau, vì vậy việc lựa chọn mô hình tối ưu nhất cho từng board cũng sẽ khác biệt:

---

1. Đối với ESP32-S3 N16R8 (Tối ưu nhất: YOLOv5-nano / YOLOv8-n hoặc FOMO nâng cao)

Chip **ESP32-S3** sở hữu tập lệnh **Vector Instructions (tăng tốc tính toán AI)**, kết hợp với **16MB Flash (N16)** và **8MB PSRAM (R8)**, cho phép nó chạy được các mô hình phát hiện đối tượng thực thụ (trả về bounding box đầy đủ) thay vì chỉ chạy được FOMO giới hạn như ESP32 thường.

- **Lựa chọn tốt nhất cho độ chính xác (Bounding Box đầy đủ): YOLOv5-nano hoặc YOLOv8-nano (được lượng tử hóa INT8).**
    - **Lý do:** Nhờ có 8MB PSRAM, ESP32-S3 hoàn toàn có thể chứa được các mô hình YOLO bản thu nhỏ. Bạn có thể sử dụng bộ khung **ESP-DL** của chính Espressif để tối ưu hóa và chạy mô hình YOLOv5-nano INT8. Tốc độ xử lý có thể đạt từ **2 đến 5 FPS** tùy thuộc vào kích thước ảnh đầu vào (thường cấu hình ở mức 192x192 hoặc 240x240).
- **Lựa chọn tốt nhất cho tốc độ (Real-time FPS cao): Mô hình FOMO (MobileNetV2 0.35 Alpha) qua Edge Impulse.**
    - **Lý do:** Nếu bạn cần tốc độ phản hồi nhanh để bắt các vật thể chuyển động nhanh (Tracking), mô hình FOMO chạy trên ESP32-S3 có thể đạt hiệu suất cực kỳ ấn tượng, lên tới **20 - 30 FPS**. Trên ESP32-S3, bạn có thể tăng độ phân giải ảnh đầu vào của FOMO lên cao hơn (ví dụ 240x240 hoặc 320x320) để nhận diện vật thể nhỏ tốt hơn mà chip vẫn không bị quá tải.

---

2. Đối với Sipeed Tang Nano 20K (Tối ưu nhất: MobileNet-SSD hoặc YOLOv2/v4-Tiny lượng tử hóa)

Tang Nano 20K là một bo mạch FPGA (sử dụng chip Gowin GW2AR-18). Sức mạnh của FPGA nằm ở khả năng tính toán song song phần cứng cực mạnh, tạo ra một **NPU (Neural Processing Unit) tùy biến** bằng cách cấu hình các khối logic core (IP core) bên trong chip.

- **Lựa chọn tốt nhất: MobileNet-YOLO, YOLOv2-Tiny hoặc MobileNet-SSD (INT8).**
    - **Lý do:** Sipeed cung cấp bộ công cụ **Gowin IP Core / Sipeed TinyMaix** để biên dịch mô hình AI thành cấu trúc mạch phần cứng trên FPGA. Do tài nguyên logic của dòng GW2AR-18 nằm ở mức vừa phải (20,736 LUTs), các mô hình dạng **YOLOv2-Tiny** hoặc các kiến trúc mạng MobileNet kết hợp với bộ phát hiện SSD (Single Shot MultiBox Detector) cấu hình thấp là phù hợp nhất.
    - **Hiệu năng:** Khác với ESP32-S3 chạy bằng lệnh phần mềm, FPGA xử lý ảnh theo luồng phần cứng trực tiếp từ camera (ví dụ như qua OV5640). Tốc độ xử lý của Tang Nano 20K với mô hình YOLOv2-Tiny lượng tử hóa có thể đạt từ **10 đến 15+ FPS** với độ chính xác nhận diện hình khối tốt hơn nhiều so với FOMO.

Tóm tắt so sánh để bạn đưa ra lựa chọn:

Bo mạch	Mô hình nên chọn	Độ chính xác	Tốc độ xử lý (FPS)	Độ khó khi triển khai
ESP32-S3 N16R8	**YOLOv5-nano** (qua ESP-DL)	Cao (Có khung bao đầy đủ)	~3 - 5 FPS	Trung bình (Code C++ thuần hoặc sử dụng ESP-IDF)
ESP32-S3 N16R8	**FOMO** (qua Edge Impulse)	Trung bình (Chỉ có tâm X, Y)	~20 - 30 FPS	Rất dễ (Hỗ trợ sẵn thư viện Arduino)
Tang Nano 20K	**YOLOv2-Tiny / MobileNet**	Khá cao (Khung bao tốt hơn FOMO)	~10 - 15 FPS	Khó (Cần sử dụng Gowin IDE, nạp file cấu hình mạch phần cứng .fs)

Lời khuyên:

- Nếu bạn muốn triển khai dự án **nhanh chóng, dễ viết code bám đuổi (Object Tracking) với Servo**, hãy dùng **ESP32-S3 với mô hình FOMO** vì Edge Impulse hỗ trợ cấu hình cực tiện lợi cho dòng N16R8.
- Nếu bạn muốn học sâu về **phần cứng AI, xử lý luồng camera mượt mà độ trễ thấp bằng phần cứng**, hãy dùng **Tang Nano 20K kết hợp mô hình YOLOv2-Tiny**.